Uniwersytet Wrocławski

CUDA część 1

platforma GPGPU w obliczeniach naukowych

Maciej Matyka

Bariery sprzętowe (procesory)

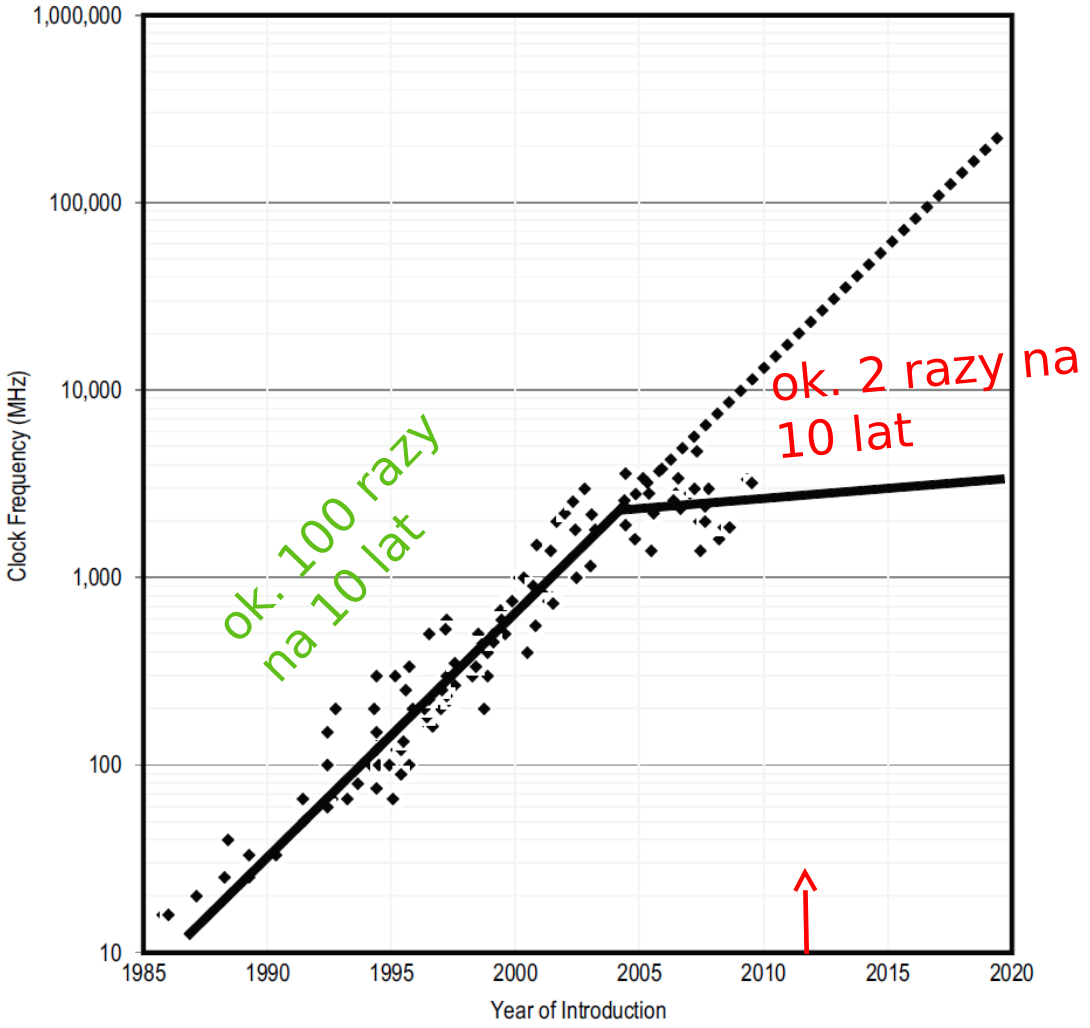

(ZK)

Uniwersytet Wrocławski

Rozwój 1985-2004 i dalej...?

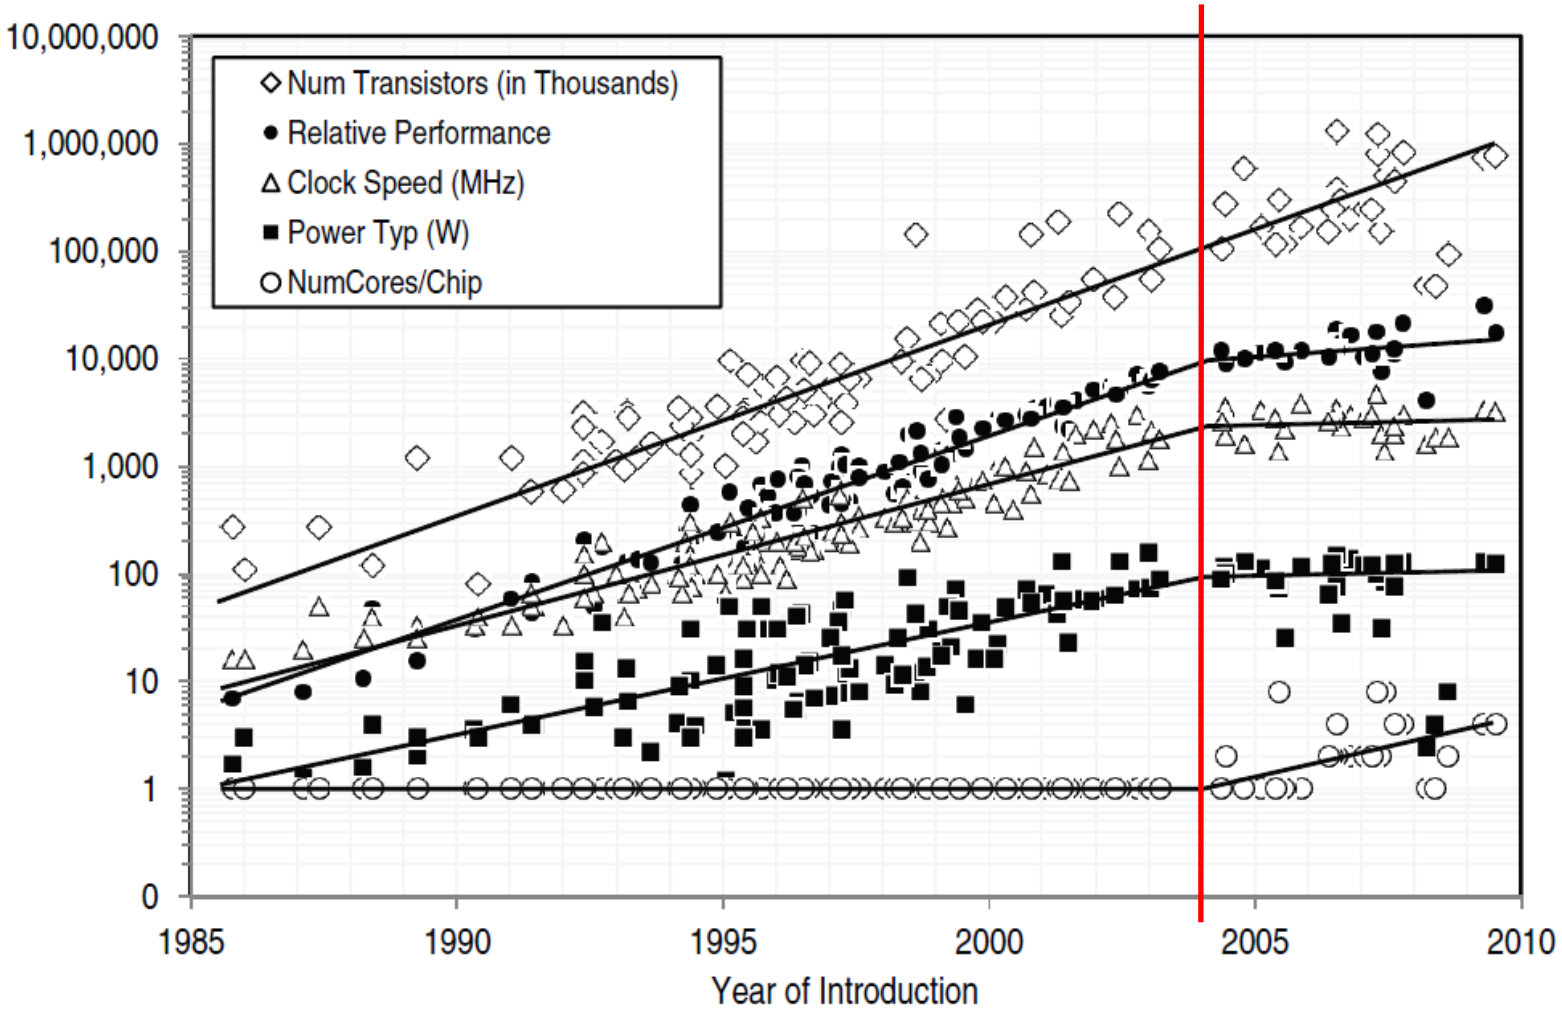

(ZK)

Specjalizowane układy graficzne

?

(ZK)

Uniwersytet Wrocławski

Obliczenia wysokiej wydajności

Superkomputer:

- Altix 3700, 128 procesorów (Intel Itanium 2)
- Używana np. w Cyfronet AGH
- 0.768 TFLOPS mocy obliczeniowej
- Cena: 1/2 miliona zł !

Uniwersytet Wrocławski

Superkomputer na biurku?

Karta graficzna:

- GeForce 285
  (używana w pokoju 521 w IFT)
- 240 procesory CUDA
- 1.06 TFLOPS mocy obliczeniowej (teoretycznie)
- Cena: 670zł

Uniwersytet Wrocławski

Rachunek wydaje się prosty..

- 1.38x więcej mocy za 0.134% ceny
- (+ energia + pomieszczenia + chłodzenie etc.)
- Zasada zachowania trudności, czyli coś za coś...
- Kartę trzeba jeszcze oprogramować!

Uniwersytet Wrocławski

GPGPU

General-purpose computing on graphics processing units

Uniwersytet Wrocławski

Gdzie umiejscowić GPGPU ?

- SISD – Single Instruction Single Data
- **SIMD – Single Instruction Multiple Data (MSIMD?)**
- SPMD – Single Process Multiple Data
- MISD – Multiple Instruction Single Data
- MIMD - Multiple Instruction Multiple Data

(http://perilsofparallel.blogspot.com/2008/09/larrabee-vs-nvidia-mimd-vs-simd.html)

Uniwersytet Wrocławski

Na jakiej platformie programować GPU?

Niskopoziomowe API

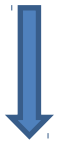

- Vertex i Pixel Shaders (OpenGL)
- Direct Compute (DirectX)
- CUDA driver API
- C runtime for CUDA
- OpenCL
- Kompilatory PGI
- OpenACC

API wysokiego poziomu

Uniwersytet Wrocławski

C runtime for CUDA

Co to jest CUDA?
Compute **U**nified **D**evice **A**rchitecture

- Platforma programowania GPU (dla kart nVidii)
- Rozszerzenie języka C
- (działa również z C++)
- kompilator (nvcc)
- zbiór dyrektyw kompilatora i dodatkowych funkcji
- Np. słowa kluczowe:
  `__device__, __host__` wyróżniające rodzaj sprzętu na którym implementowana jest funkcja lub dana
- Np. funkcja:
  `cudaMemcpy(…)`
  (kopiowanie pamięci CPU <-> GPU)

CUDA pod Windows

- Microsoft Visual C++ (2008, 2010)
  – można użyć darmowej wersji Express
- Sterownik (ze strony Parallel NSIGHT):
- CUDA Toolkit
- CUDA SDK
- nVidia Parallel NSIGHT HOST/MONITOR

Uniwersytet Wrocławski

CUDA pod LINUX-em

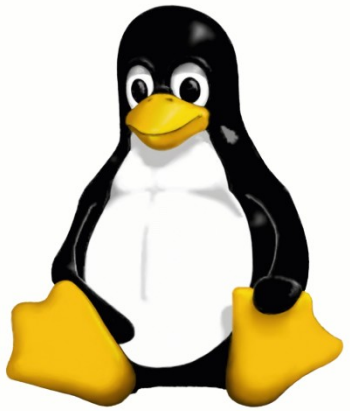

- Inaczej niż pod Windows
  – nie używamy Parallel Nsight
- Sterowniki **nvidia-current** (repozytoria)
- Cuda Toolkit (biblioteki, pliki nagłówkowe, .so)
- Po zainstalowaniu kompilacja (plik program.cu):

```
> nvcc program.cu
> ./a.out
```

Hello World

- Pierwszy prosty program w CUDA

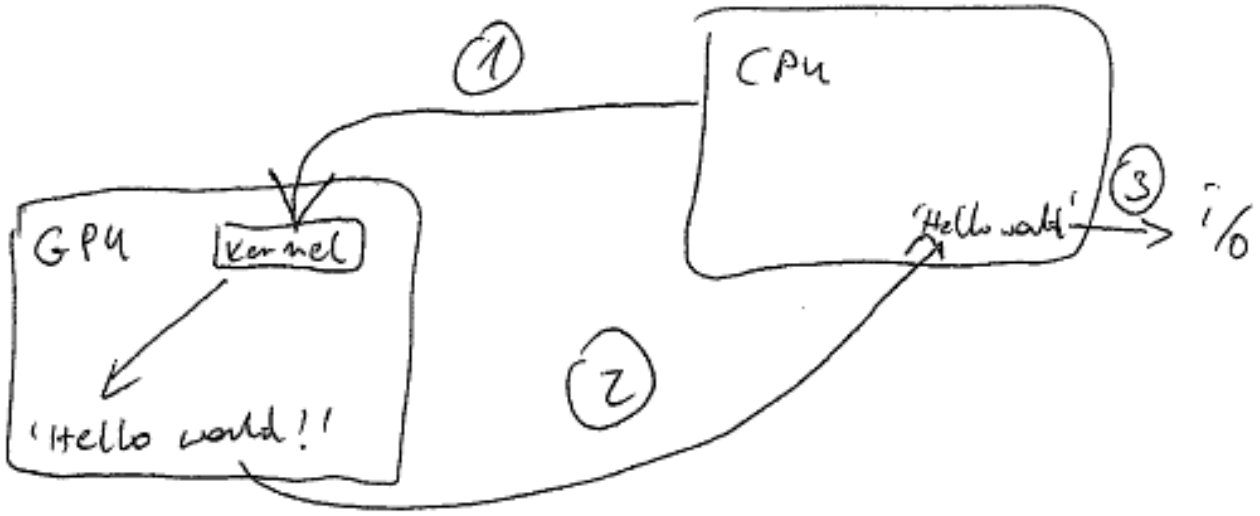

1. CP
   - Funkcja wstawia do pamięci GPU ciąg „Hello world!”
2. Kopiujemy dane z GPU do pamięci CPU
3. Dane wypisujemy przy pomocy funkcji i/o (cout etc.)

Hello World

- Pierwszy prosty program w CUDA

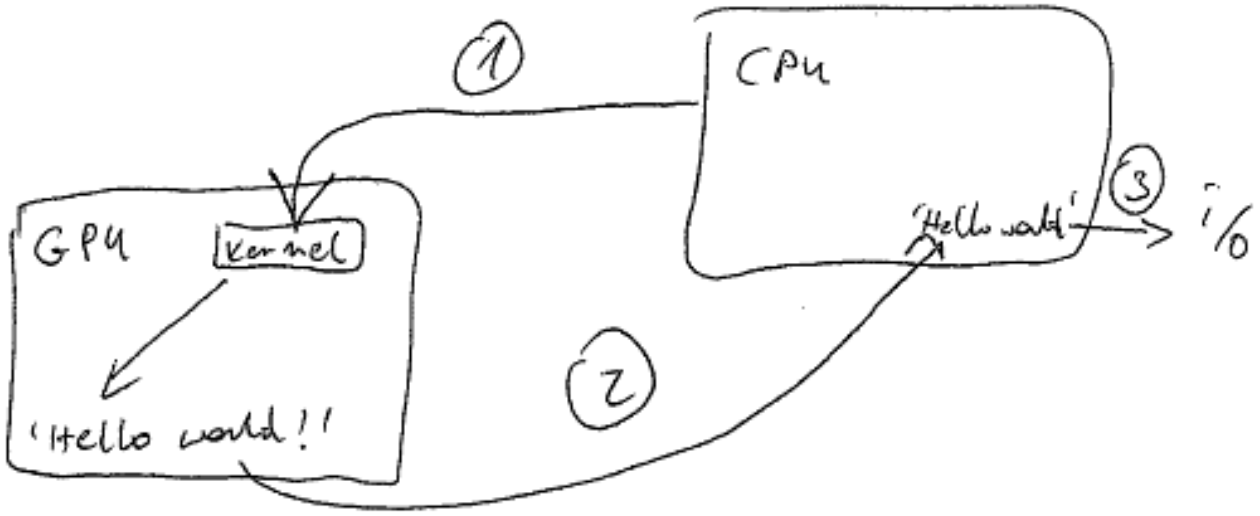

1. CP
   - Fu..kcja wstawia do pamięci GPU ciąg „Hello world!"
2. Kopiujemy dane z GPU do pamięci CPU
3. Dane wypisujemy przy pomocy funkcji i/o (cout etc.)

Uniwersytet Wrocławski

Hello World

```
#include <stdio.h>
#include <cuda.h>

__device__ char napis_device[14];

__global__ void helloWorldOnDevice(void)
{
    napis_device[0] = 'H';
    napis_device[1] = 'e';
    …
    napis_device[11] = '!';
    napis_device[12] = '\n';
    napis_device[13] = 0;
}

int main(void)
{
    helloWorldOnDevice <<< 1, 1 >>> ();

    char napis_host[14];
    const char *symbol="napis_device";

    cudaMemcpyFromSymbol (napis_host,
    symbol, sizeof(char)*13, 0,
    cudaMemcpyDeviceToHost);

    printf("%s",napis_host);
}
```

Uniwersytet Wrocławski

Hello World

```
#include <stdio.h>
#include <cuda.h>

__device__ char napis_device[14];

__global__ void helloWorldOnDevice(void)
{
    napis_device[0] = 'H';
    napis_device[1] = 'e';
    …
    napis_device[11] = '!';
    napis_device[12] = '\n';
    napis_device[13] = 0;
}

int main(void)
{
    helloWorldOnDevice <<< 1, 1 >>> ();

    char napis_host[14];
    const char *symbol="napis_device";

    cudaMemcpyFromSymbol (napis_host,
    symbol, sizeof(char)*13, 0,
    cudaMemcpyDeviceToHost);

    printf("%s",napis_host);
}
```

Uniwersytet Wrocławski

Hello World

```
#include <stdio.h>
#include <cuda.h>

__device__ char napis_device[14];

__global__ void helloWorldOnDevice(void)
{
    napis_device[0] = 'H';
    napis_device[1] = 'e';
    …
    napis_device[11] = '!';
    napis_device[12] = '\n';
    napis_device[13] = 0;
}

int main(void)
{
    helloWorldOnDevice <<< 1, 1 >>> ();

    char napis_host[14];
    const char *symbol="napis_device";

    cudaMemcpyFromSymbol (napis_host,
    symbol, sizeof(char)*13, 0,
    cudaMemcpyDeviceToHost);

    printf("%s",napis_host);
}
```

Uniwersytet Wrocławski

Hello World

```
#include <stdio.h>
#include <cuda.h>

__device__ char napis_device[14];

__global__ void helloWorldOnDevice(void)
{
    napis_device[0] = 'H';
    napis_device[1] = 'e';
    …
    napis_device[11] = '!';
    napis_device[12] = '\n';
    napis_device[13] = 0;
}

int main(void)
{
    helloWorldOnDevice <<< 1, 1 >>> ();

    char napis_host[14];
    const char *symbol="napis_device";

    cudaMemcpyFromSymbol (napis_host,
    symbol, sizeof(char)*13, 0,
    cudaMemcpyDeviceToHost);

    printf("%s",napis_host);
}
```

Uniwersytet Wrocławski

Hello World

```
#include <stdio.h>
#include <cuda.h>

__device__ char napis_device[14];

__global__ void helloWorldOnDevice(void)
{
    napis_device[0] = 'H';
    napis_device[1] = 'e';
    …
    napis_device[11] = '!';
    napis_device[12] = '\n';
    napis_device[13] = 0;
}

int main(void)
{
    helloWorldOnDevice <<< 1, 1 >>> ();

    char napis_host[14];
    const char *symbol="napis_device";

    cudaMemcpyFromSymbol (napis_host,
    symbol, sizeof(char)*13, 0,
    cudaMemcpyDeviceToHost);

    printf("%s",napis_host);
}
```

Hello World

```
#include <stdio.h>
#include <cuda.h>

__device__ char napis_device[14];

__global__ void helloWorldOnDevice(void)
{
    napis_device[0] = 'H';
    napis_device[1] = 'e';
    …
    napis_device[11] =
    napis_device[12] =
    napis_device[13] =
}

int main(void)
{
    helloWorldOnDevice <<< 1, 1 >>> ();

    char napis_host[14];
    const char *symbol="napis_device";

    cudaMemcpyFromSymbol (napis_host,
    symbol, sizeof(char)*13, 0,
    cudaMemcpyDeviceToHost);

    printf("%s",napis_host);
}
```

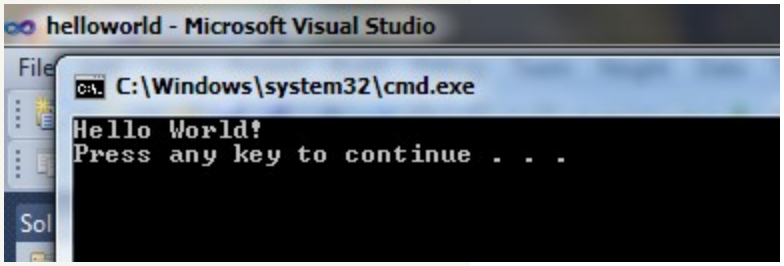

Uniwersytet Wrocławski

Deklaracja funkcji na GPU

- Funkcja uruchamiana na GPU to kernel (jądro)
- Zmienne na GPU – przedrostek **__device__**
- Preambuła jądra - przedrostek **__global__**

```
char napis_device[14];

void helloWorldOnDevice(void)
{
    napis_device[0] = 'H';
    napis_device[1] = 'e';
    …
    napis_device[11] = '!';
    napis_device[12] = '\n';
    napis_device[13] = 0;
}
```

```
__device__ char napis_device[14];

__global__ void helloWorldOnDevice(void)
{
    napis_device[0] = 'H';
    napis_device[1] = 'e';
    …
    napis_device[11] = '!';
    napis_device[12] = '\n';
    napis_device[13] = 0;
}
```

Uniwersytet Wrocławski

Wywołanie funkcji na GPU

- Wywołanie funkcji GPU:

```
funkcja <<< numBlocks, threadsPerBlock >>> ( parametry );
```

- numBlocks – liczba bloków w macierzy wątków
- threadsPerBlock – liczba wątków na blok

W naszym przykładzie <<<1,1>>> oznaczało uruchomienie jądra na jednym wątku który zawierał się w jednym jedynym bloku macierzy wątków.

Uniwersytet Wrocławski

numBlocks, threadsPerBlock

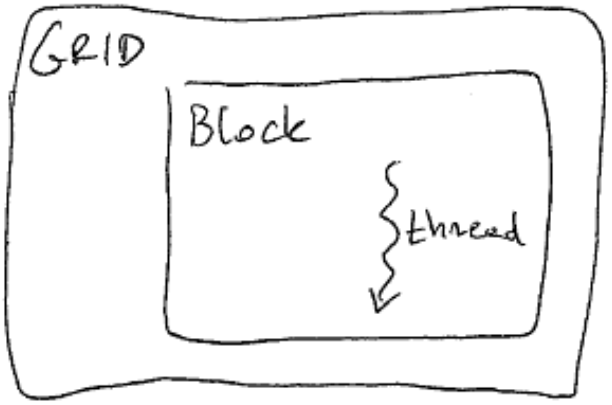

<<< 1 , 1 >>>

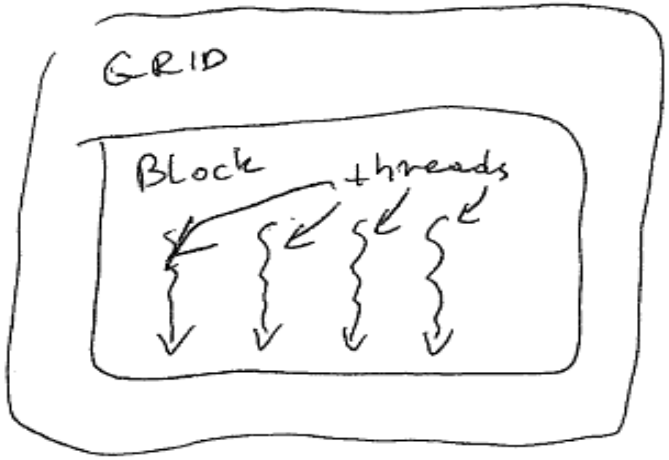

<<< 1 , 4 >>>

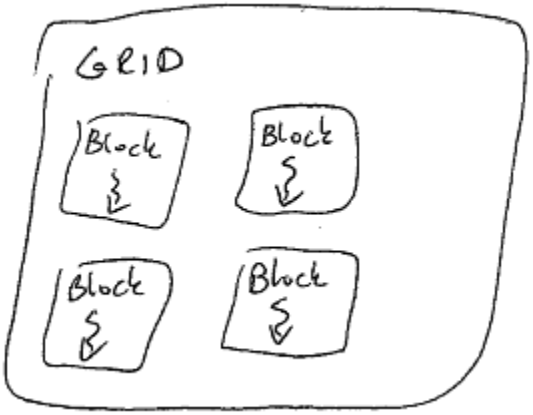

<<<4 ,1>>>

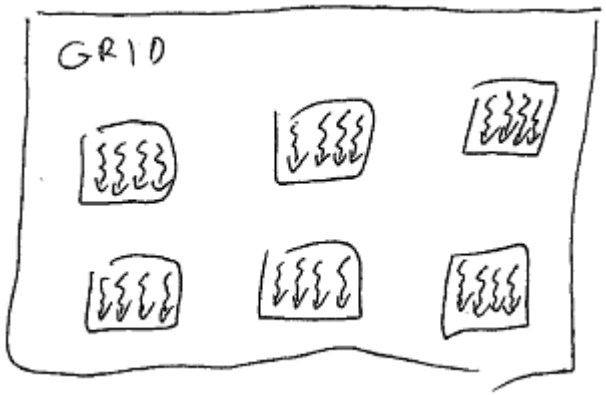

<<< dim3(3,2,1) , 4 >>>

Uniwersytet Wrocławski

A tak to widzi nVidia

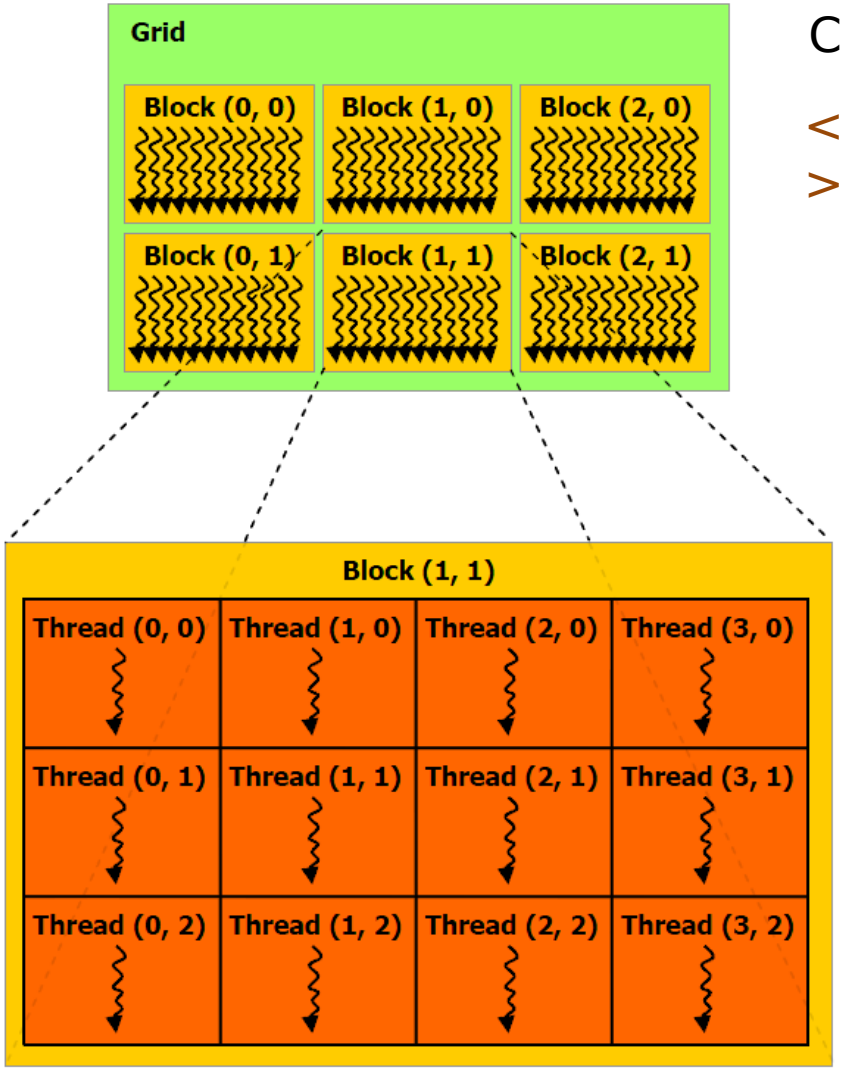

Figure 2-1. Grid of Thread Blocks

CUDA Programming Guide 3.2

<<< dim3(3,2,1) , dim3(4,3,1) >>>

Hello World wielowątkowo

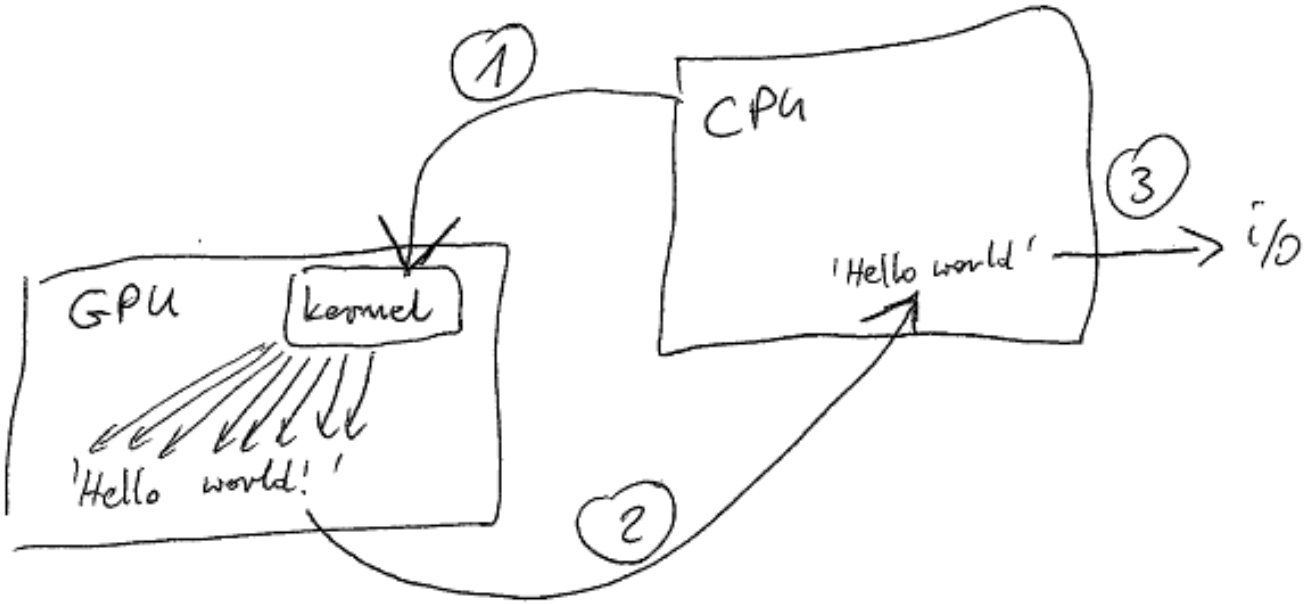

1. C
   - Fu
   - je

(pomoc: P. Czubiński)

Hello World wielowątkowo

- jedna litera na jeden wątek

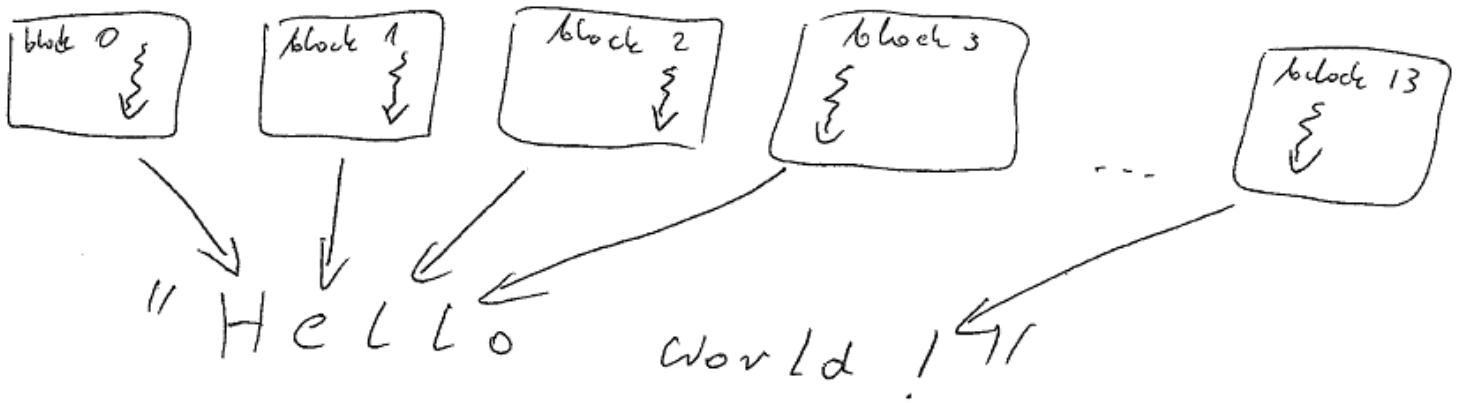

- stwórzmy 14 bloków po 1 wątku
- Każdy wątek „widzi” swój numer i numer bloku
- Numer bloku -> miejsce w tablicy do skopiowania

Hello World wielowątkowo

- Jądro dla hello world w wersji wielowątkowej:

```
__constant__ __device__ char hw[] = "Hello World!\n";
__device__ char napis_device[14];

__global__ void helloWorldOnDevice(void)
{
    int idx = blockIdx.x;
    napis_device[idx] = hw[idx];
}

…

helloWorldOnDevice <<< 14, 1 >>> ();
```

- id
  - zawiera numer bloku w którym znajduje się wątek
    - mapowanie blok/wątek -> fragment problemu
  - wątek z idx-ego bloku kopiuje idx-ą literę napisu
  - Kopiowanie GPU-GPU
    - (bez sensu, ale chodzi nam o najprostszy problem)

Hello World wielowątkowo

- Jądro dla hello world w wersji wielowątkowej:

```
__constant__ __device__ char hw[] = "Hello World!\n";
__device__ char napis_device[14];

__global__ void helloWorldOnDevice(void)
{
    int idx = blockIdx.x;
    napis_device[idx] = hw[idx];
}

…

helloWorldOnDevice <<< 14, 1 >>> ();
```

- id
  - zawiera numer bloku w którym znajduje się wątek
    - mapowanie blok/wątek -> fragment problemu
  - wątek z idx-ego bloku kopiuje idx-ą literę napisu
  - Kopiowanie GPU-GPU
    - (bez sensu, ale chodzi nam o najprostszy problem)

Hello World wielowątkowo

- Jądro dla hello world w wersji wielowątkowej:

```
__constant__ __device__ char hw[] = "Hello World!\n";
__device__ char napis_device[14];

__global__ void helloWorldOnDevice(void)
{
    int idx = blockIdx.x;
    napis_device[idx] = hw[idx];
}

…

helloWorldOnDevice <<< 14, 1 >>> ();
```

- id
  - zawiera numer bloku w którym znajduje się wątek
    - mapowanie blok/wątek -> fragment problemu
  - wątek z idx-ego bloku kopiuje idx-ą literę napisu
  - Kopiowanie GPU-GPU
    - (bez sensu, ale chodzi nam o najprostszy problem)

Hello World wielowątkowo

- Jądro dla hello world w wersji wielowątkowej:

```
__constant__ __device__ char hw[] = "Hello World!\n";
__device__ char napis_device[14];

__global__ void helloWorldOnDevice(void)
{
    int idx = blockIdx.x;
    napis_device[idx] = hw[idx];
}

…

helloWorldOnDevice <<< 14, 1 >>> ();
```

- id
  - zawiera numer bloku w którym znajduje się wątek
    - mapowanie blok/wątek -> fragment problemu
  - wątek z idx-ego bloku kopiuje idx-ą literę napisu
  - Kopiowanie GPU-GPU
    - (bez sensu, ale chodzi nam o najprostszy problem)

W praktyce

Uniwersytet Wrocławski

Modele ośrodków porowatych

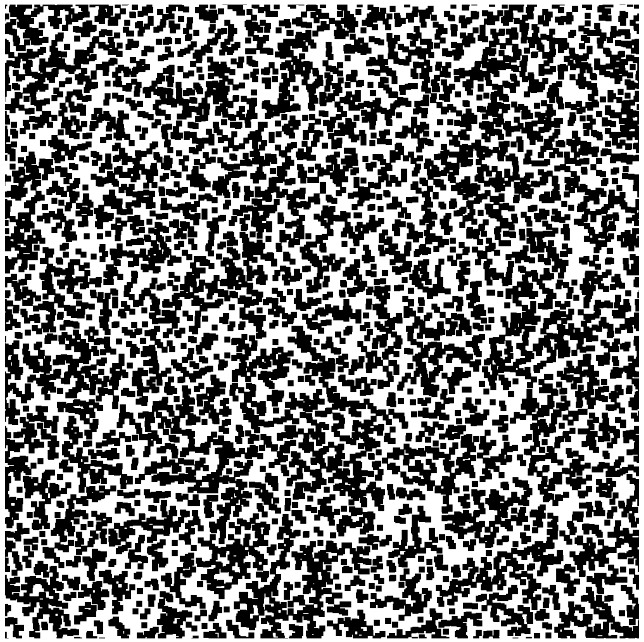

P=0.4

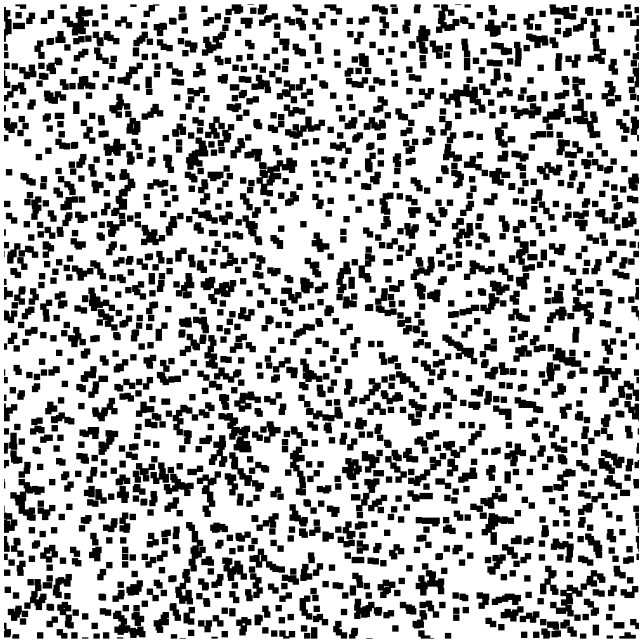

P=0.7

Ogromne układy (miliony komórek obliczeniowych).

Uniwersytet Wrocławski

Przykład rozwiązania

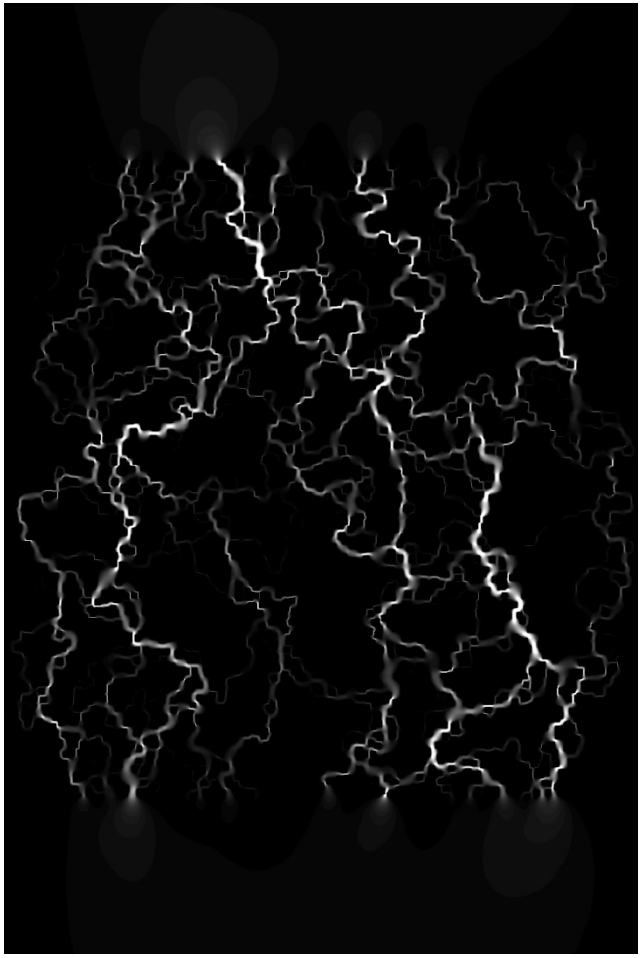

P=0.4, T=1.7

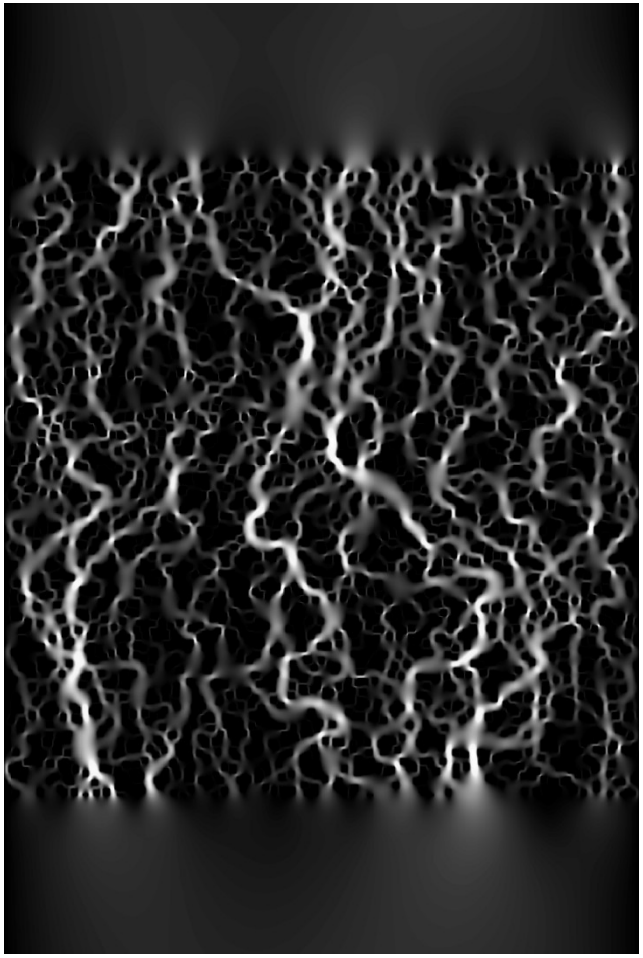

P=0.7 , T=1.28

Model gazu sieciowego LGA

- Uproszczenie: model gazu sieciowego opisany przez U. Frisha, B. Hasslachera i Y. Pomeau gaz FHP

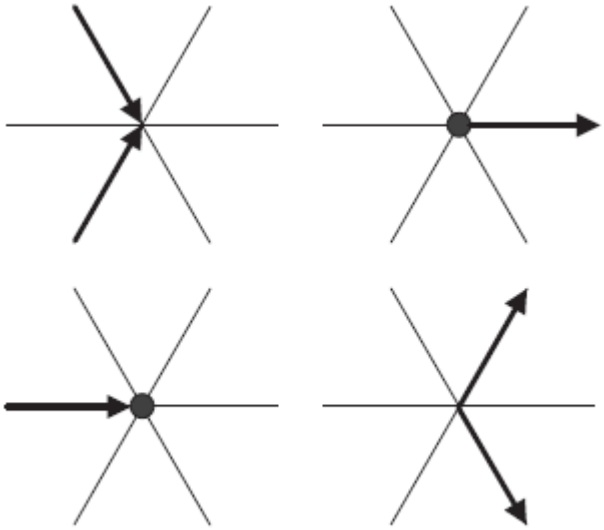

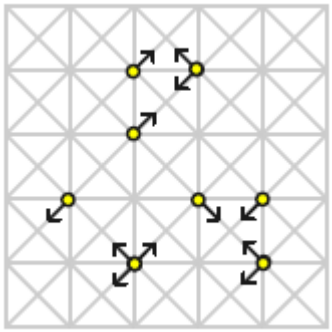

1) Transport
2) Kolizje

Rys. Kolizje w modelu FHP5

U. Frish, B. Hasslacher, Y. Pomeau 1986 *Lattice-Gas Automata for the Navier-Stokes Equation*, Phys. Rev. Lett. 56, 1505–1508.

Matyka, M. and Koza, Z., *Spreading of a density front in the Kuentz-Lavallee model of porous media* J. Phys. D: Appl. Phys. 40, 4078-4083 (2007)

Metoda gazu sieciowego Boltzmanna

- Historycznie wprowadzona jako rozwinięcie LGA

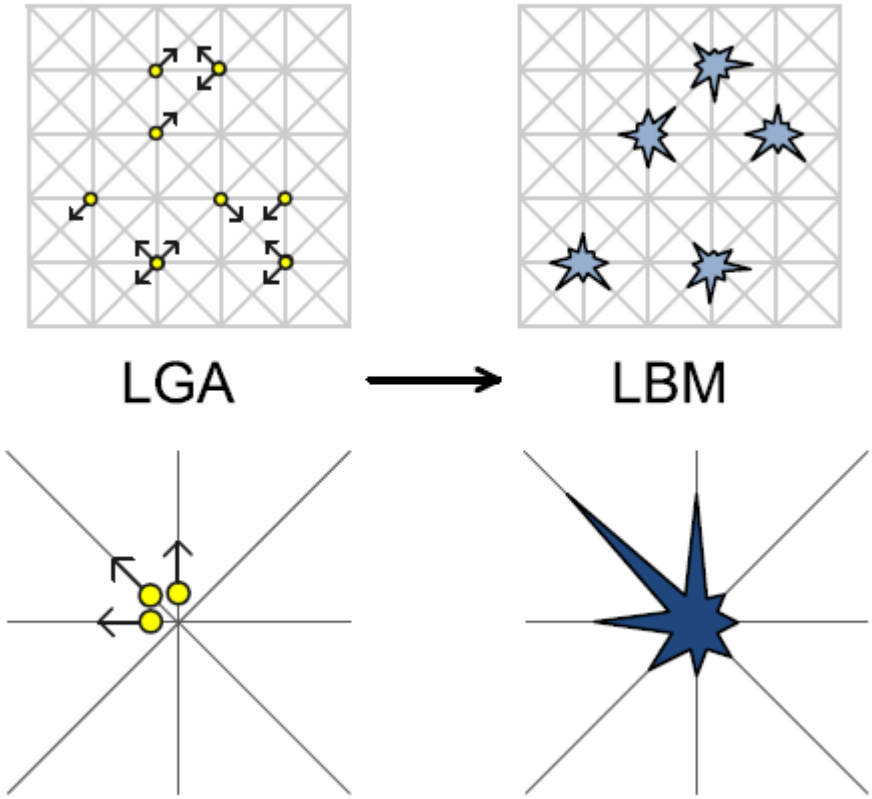

- Zmienne n_i

$$f_i \in [0, 1]$$

Uniwersytet Wrocławski

Podstawowy Algorytm LBM

Podstawowy algorytm LBM to dwa kroki:

- kolizji:

$$\tilde{f}_i(\mathbf{x}, t) = f_i(\mathbf{x}, t) - \frac{1}{\tau}(f_i(\mathbf{x}, t) - f_i^{eq}(\mathbf{x}, t))$$

- transp

$$f_i(\mathbf{x} + \mathbf{c}_i, t + 1) = \tilde{f}_i(\mathbf{x}, t).$$

Lokalność!

Przykład działania LBM na CUDA

- 512 x 512

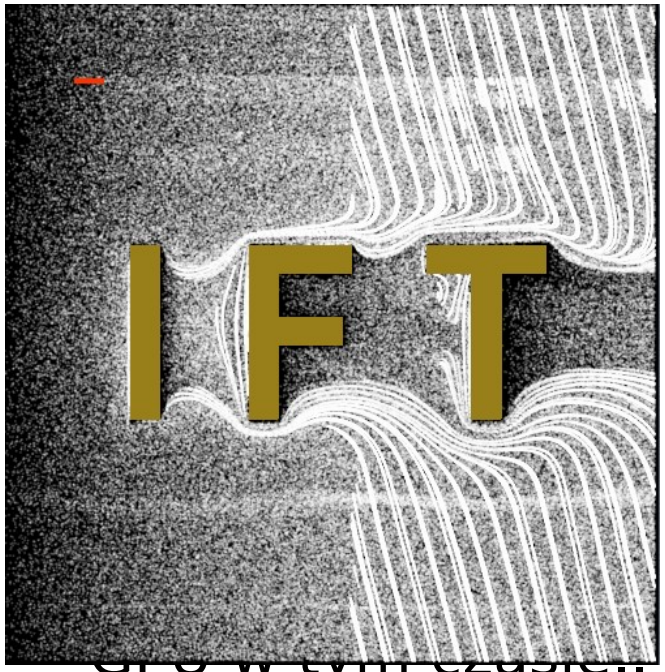

- GPU stoi...

...GPU w tym czasie...

(przykład cpu, gpu)

Hydrodynamika cząstek rozmytych

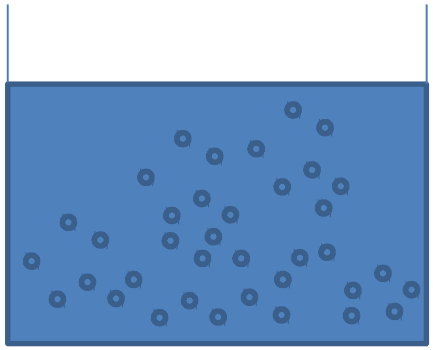

1. Lagrangian Fluid Dynamics, Using Smoothed Particle Hydrodynamics, Micky Kelager, 2006

2. http://pl.wikipedia.org/wiki/SPH)

- Podejście Lagrange'a (ruchome punkty)
- Każda cząstka reprezentuje pewną objętość cieczy
- Wielkości fizyczne interpolowane po sąsiadach

$$A_i = \sum_{j=1}^{N} m_j \frac{A_j}{\rho_j} W_{ij}$$

- Gdzie Wij jest tytułowym „rozmyciem" np.

$$W_{default}(\mathbf{r},h) = \frac{315}{64\pi h^9} \begin{cases} \left(h^2 - \|\mathbf{r}\|^2\right)^3 & 0 \le \|\mathbf{r}\| \le h \\ 0 & \|\mathbf{r}\| > h, \end{cases}$$

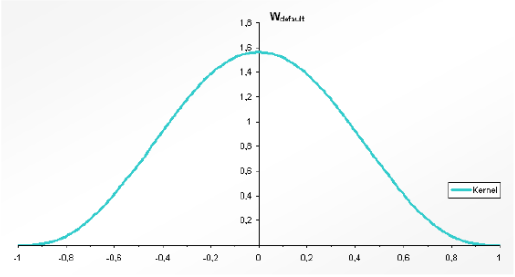

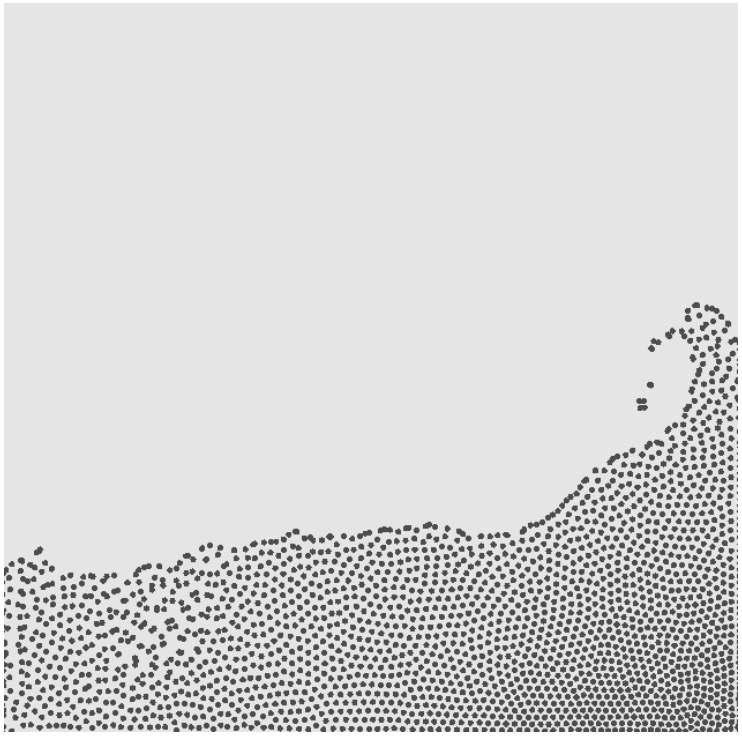

Rys. Algorytm SPH na CUDA (GTX285).

(w działaniu)

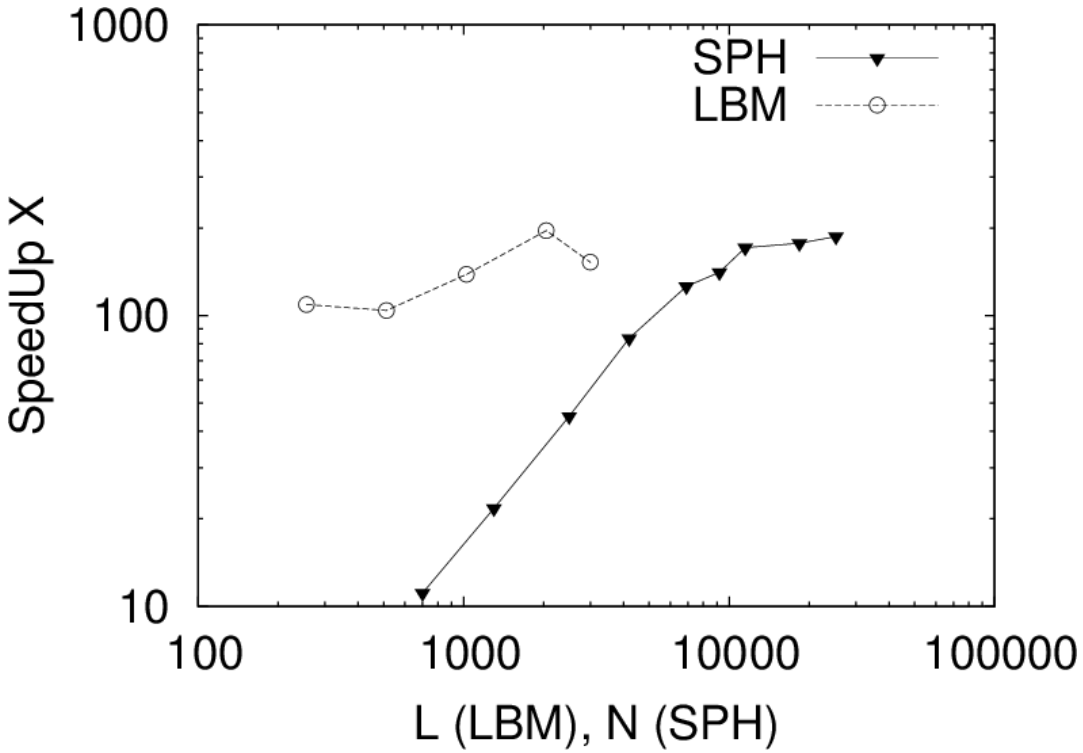

Rys. Skalowanie algorytmów LBM i SPH na karcie GTX 285 względem jednego rdzenia CPU.

Uniwersytet Wrocławski

Łyżka dziegciu

Debunking the 100X GPU vs. CPU Myth: An Evaluation of Throughput Computing on CPU and GPU

Victor W Lee†, Changkyu Kim†, Jatin Chhugani†, Michael Deisher†, Daehyun Kim†, Anthony D. Nguyen†, Nadathur Satish†, Mikhail Smelyanskiy†, Srinivas Chennupaty*, Per Hammarlund*, Ronak Singhal* and Pradeep Dubey†

victor.w.lee@intel.com

†Throughput Computing Lab, Intel Corporation

*Intel Architecture Group, Intel Corporation

Uniwersytet Wrocławski

Analiza wydajności CPU / GPU

- Przypadek testowy: driven cavity 3d
- Porównanie czasów określonej liczby iteracji
- Kody: Palabos (MPI) i Sailfish (CUDA)

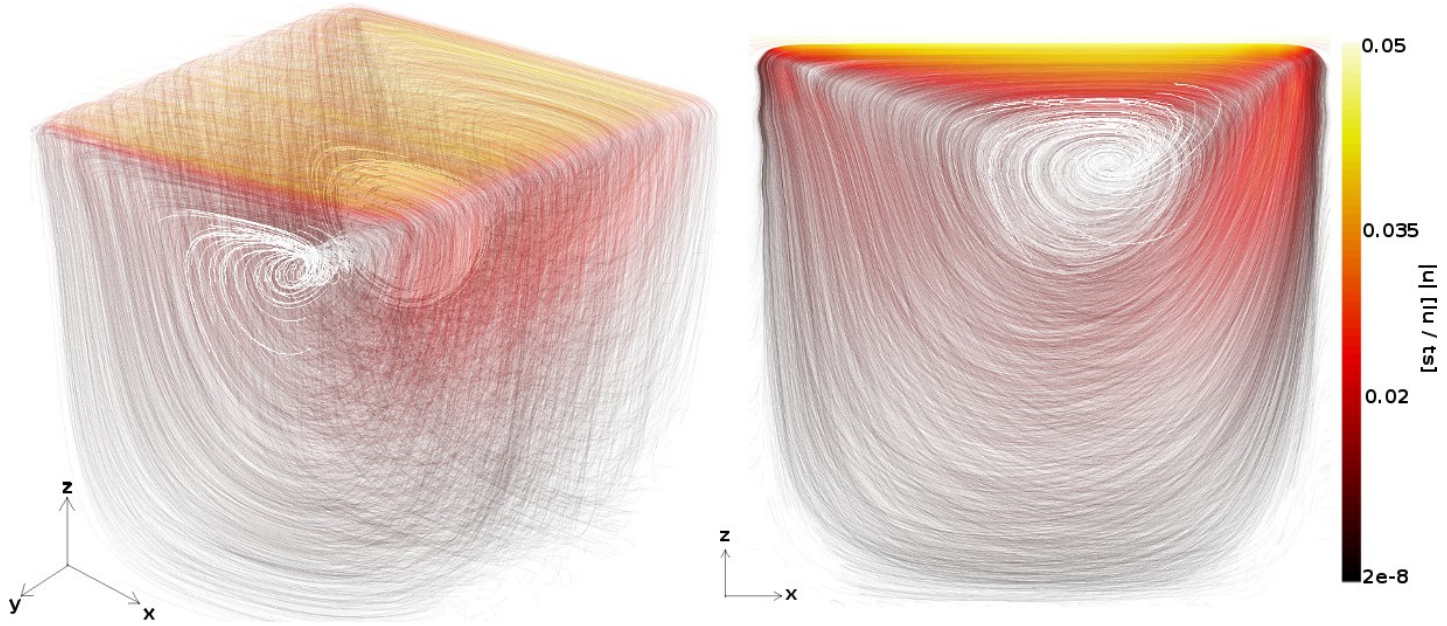

Rys: Wizualizacja przepływu przez trójwymiarową komorę wyznaczonego kodem Sailfish dla liczby Reynoldsa Re=100.

Matyka, M., Miroslaw, Ł., Koza,Z., *Wydajność otwartych implementacji metody sieciowej Boltzmanna na CPU i GPU*, (KOWBAN) XVIII (2011)

Uniwersytet Wrocławski

Wydajność Sailfish / Palabos

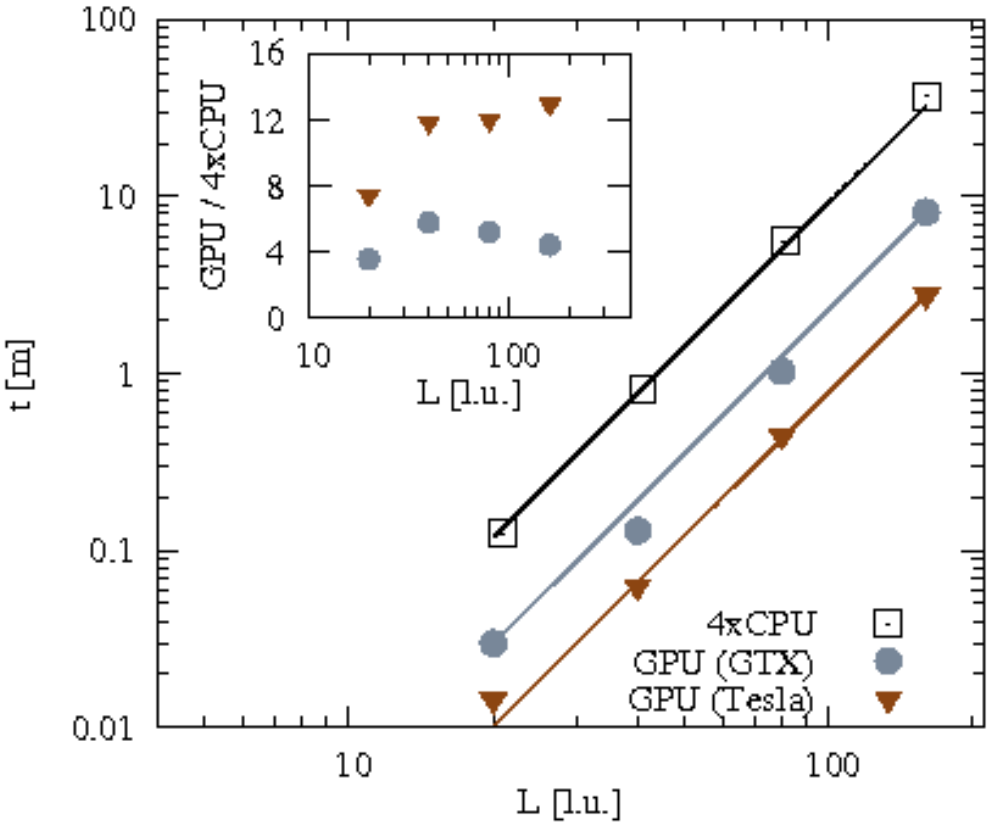

Czas wykonania 30000 kroków na 4xCPU i GPU (Gtx460 i Tesla).

Matyka, M., Miroslaw, Ł., Koza,Z., *Wydajność otwartych implementacji metody sieciowej Boltzmanna na CPU i GPU*, (KOWBAN) XVIII (2011)

Przyszłość?

Niskopoziomowe API

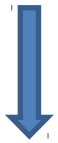

- Vertex i Pixel Shaders (OpenGL)
- Direct Compute (DirectX)
- CUDA driver API
- C runtime for CUDA
- OpenCL
- Kompilatory PGI
- OpenACC

API wysokiego poziomu

Czym się zajmujemy?

- Grant MNiSW Grant N N519 437939
  - Przepływ płynu (LBM) w ośrodkach porowatych na GPU
- Projekt Zielony Transfer (Vratis Sp. z o.o.) akceleracja CFD metod FVM na GPU – 2011
- Akceleracja obliczeń macierzowych (z Z. Kozą, J. Połą) na GPU
- Wizualizacja przepływów 3D w ośrodkach porowatych z użyciem OpenCL (multi GPU)
-

http://people.brunel.ac.uk/bst/vol1201/rebeccaclunn/home.html

Uniwersytet Wrocławski

Dziękuję za uwagę